

Mudette

Glosario de comandos y scripts

Referencia visual para ejecutar la demo, tests y benchmarks.

Los benchmarks sin juez son offline (sin API keys).

Agente y juez usan API keys separadas cuando estan online.

Nexa Copilot + MTGuard

Mapa rapido: que script usar

Quiero...	Script
Instalar el proyecto	setup.sh
Abrir la demo web	run-demo.sh
Correr todos los tests	run-tests.sh
Benchmarks sin juez (CI)	run-benchmarks-no-judge.sh
Benchmarks con juez LLM	run-benchmarks-with-judge.sh
Un ataque concreto	run-scenario.sh <id>
Verificar corpus benigno	run-benign-check.sh
Regenerar KB FAISS	build-kb.sh
Este PDF	generate-glossary-pdf.sh

1. Primeros pasos

setup.sh

Instalar dependencias

[./scripts/setup.sh](#)

Descarga e instala Python, librerías (Gradio, FAISS, OpenAI) y herramientas de desarrollo con uv.

API keys: No requiere API keys

Cuando: Primera vez que clonas el repo o tras cambiar pyproject.toml

build-kb.sh

Construir base de conocimiento

[./scripts/build-kb.sh](#)

Regenera el índice FAISS y chunks.json desde los markdown en demo_pack/nexa_copilot/kb_src/.

API keys: No requiere API keys

Cuando: Tras editar documentación IT en kb_src/

2. Ejecutar la demo

run-demo.sh

Abrir la demo web

[./scripts/run-demo.sh](#)

equiv: uv run Mudette-demo

Inicia Gradio en <http://localhost:7860>. Chat con Nexa Copilot, panel TurnTrace, playbooks y capas L1→L2→Fusion.

API keys: Opcional: API key agente (gpt-4o) + API key juez (gpt-4o-mini), separados: Probar la demo interactiva con modo benigno o red team

3. Tests y calidad

run-tests.sh

Suite completa pytest

[./scripts/run-tests.sh](#)

equiv: `uv run pytest -v`

Ejecuta todos los tests offline: L1, L2, fusion, RAG, agente, playbooks y UI.

API keys: No requiere API keys

Cuando: Antes de commit/PR o para validar el repo

run-benign-check.sh

Corpus benigno sin CONTAIN

[./scripts/run-benign-check.sh](#)

Tests focalizados: 42+ mensajes de soporte IT nunca deben recibir veredicto CONTAIN.

API keys: No requiere API keys

Cuando: CI rápido o verificar falsos positivos en L1/Fusion

4. Benchmarks (playbooks de ataque)

run-benchmarks.sh

Benchmarks por defecto (sin juez)

[./scripts/run-benchmarks.sh](#)

Alias de run-benchmarks-no-judge.sh. Ejecuta los 3 escenarios de ataque y comprueba expect_min_verdict.

API keys: No requiere API keys

Cuando: Medir defensa MTGuard offline (crescendo, salami, jailbreak)

run-benchmarks-no-judge.sh

Benchmarks sin EscalationJudge

[./scripts/run-benchmarks-no-judge.sh](#)

equiv: uv run Mudette-scenario --all

Pipeline L1→L2→Fusion→UserGate solamente. Rápido y reproducible sin llamadas OpenAI.

API keys: No requiere API keys

Cuando: CI, regresiones de risk_score y veredictos

run-benchmarks-with-judge.sh

Benchmarks con juez online

[export JUDGE_API_KEY='sk-...'](#)

[./scripts/run-benchmarks-with-judge.sh](#)

equiv: uv run Mudette-scenario --all --judge --judge-api-key \$JUDGE_API_KEY

Igual que los benchmarks pero activa EscalationJudge (modelo ligero) en turnos WATCH/ALERT con risk≥55.

API keys: Obligatorio: JUDGE_API_KEY. Opcional: MAIN_API_KEY

Cuando: Probar capa de juez con sesgo ALLOW y DENY→CONTAIN

run-scenario.sh

Un solo escenario

[./scripts/run-scenario.sh](#) [crescendo_credentials](#)

equiv: uv run Mudette-scenario --scenario jailbreak_direct

Ejecuta un playbook concreto y muestra risk_score por turno.

API keys: No requiere API keys (salvo flags --judge)

Cuando: Depurar un ataque específico

5. Documentación

generate-glossary-pdf.sh

Este glosario en PDF

[./scripts/generate-glossary-pdf.sh](#)

Genera docs/Mudette-Command-Glossary.pdf con todas las órdenes explicadas visualmente.

API keys: No requiere API keys

Cuando: Compartir referencia con el equipo

Comandos uv / entry points

Comando	Que hace	Ejemplo
Mudette-demo	Demo web Gradio (:7860)	uv run Mudette-demo
Mudette-scenario --all	Todos los benchmarks de ataque	uv run Mudette-scenario --all
Mudette-scenario --scenario ID	Un escenario	uv run Mudette-scenario --scenario crescendo_credentials
pytest	Tests offline	uv run pytest -v
build_kb.py	Índice FAISS	uv run python scripts/build_kb.py

Variables de entorno (benchmarks con juez)

JUDGE_API_KEY - Obligatoria para run-benchmarks-with-judge.sh

MAIN_API_KEY - Opcional; agente Nexa online durante benchmark

Flujo recomendado

1. ./scripts/setup.sh
2. ./scripts/run-tests.sh
3. ./scripts/run-benchmarks-no-judge.sh
4. ./scripts/run-demo.sh